

AI in Biomedical Imaging Assignments for Week 5-6

20244109 기계공학과 권혁술

Problem 1

1-1)

문제 1-1에서는 세 가지 서로 다른 신경망 구조(baseline, wide, deep UNet) 모델을 각각 20 epoch 동안 학습을 진행했다. 학습을 위해 complex field의 amplitude와 phase를 모두 고려하는 L1 손실 함수를 사용했고, phase 성분의 안정적인 학습을 위해 위상 값은 2π 를 곱해 정규화 되었다. 학습이 완료된 후에는, 거리 10mm에서 수집된 테스트 data set을 사용하여 모델 평가를 진행했다. 평가는 복원된 진폭을 중심으로 수행되었으며, PSNR(피크 신호 대 잡음비)과 SSIM(구조 유사도 지수)을 정량적 지표로 사용했다. 또한 각 모델의 예측 진폭 출력을 시각화하여 성능을 정성적으로 비교했다.

모델 구조가 복원 성능에 어떤 영향을 미치는지 더 잘 이해하기 위해, 세 가지 U-Net 변형 모델인 Base, Wide, 그리고 Deep 모델을 비교했다. Base 모델은 두 단계의 인코더-디코더 구조에 64-128 채널을 사용한 기본 구조를 따랐고, Wide 모델은 깊이는 동일하게 유지하면서 채널 수를 128-256으로 증가시켰고, Deep 모델은 추가적인 인코더-디코더 단계를 포함시켜 64-128-256 채널의 세 단계 구조로 설계했다.




Figure 1. Structure Comparison between three models

학습과 검증 손실 곡선을 비교했을 때, deep 모델이 가장 낮은 손실을 보여줬다. wide 모델은 base 모델과 비교했을 때 큰 차이를 보이지 못한 것을 확인할 수 있다. Base 모델과 wide 모델 모두 학습 손실은 평탄하게 감소했지만, 검증 손실에서 fluctuation을 보였다. 이 결과를 통해, 단순히 모델을 넓게 만드는 것보다 깊게 쌓는 것이 이 문제에 더 효과적인 방법이라는 걸 알 수 있었다.

각 모델의 성능은 테스트 세트(10 mm)에서 복원된 진폭을 기준으로 PSNR과 SSIM을 계산해 비교했다. 아래 표는 50개의 테스트 샘플에 대해 계산한 두 지표의 평균값을 정리한 것이다:

	PSNR_mean	SSIM_mean	n_samples
model			
baseline	20.578605	0.342762	50
wide	20.552808	0.363340	50
deep	21.200727	0.478778	50

Figure 2. PSNR/SSIM Evaluation between three models

deep 모델은 PSNR과 SSIM 모두에서 가장 높은 값을 기록했다. 이는 픽셀 단위 정확도와 시각적 유사성 측면 모두에서 정답과 가장 가까운 복원 결과를 냈다는 의미라고 볼 수 있다. wide 모델은 SSIM에서는 baseline보다 약간 나은 성능을 보였지만, PSNR에서는 차이가 거의 없었다. 이는 과적합 가능성이 존재할 수 있다는 것을 말해준다.

아래 이미지는 각 모델들을 사용해 test set의 첫 번째 샘플을 복원한 결과를 보여준다. 상단 행에서는 왼쪽이 입력 홀로그램(강도), 가운데가 진짜 진폭, 오른쪽이 복원된 진폭이다. 하단 행에서는 가운데가 참값 위상, 오른쪽이 복원된 위상을 나타낸다. 참값 진폭과 위상 값은 데이터셋 내 복소장(complex field) 데이터에서 추출했고, 입력 홀로그램은 해당하는 intensity 파일에서 가져왔다. 이 비교를 통해 네트워크가 입력 홀로그램으로부터 진폭과 위상을 얼마나 잘 복원했는지 확인할 수 있었다.




Figure 3. Base Model Reconstructed Result




Figure 4. Wide Model Reconstructed Results




Figure 5. Deep Model Reconstructed Results

deep 모델은 이 중에서 가장 선명한 출력을 보여줬고, baseline 모델은 전체적으로 흐릿한 결과를 나타냈다. wide 모델은 위상 복원 과정에서 간헐적으로 노이즈가 발생하기도 했다. 이러한 시각적 결과와 정량적 평가를 종합하면, holographic 복원 정확도에서 네트워크의 폭보다는 깊이가 더 중요한 역할을 한다는 결론을 내릴 수 있었다.

1-2)

문제 1-2에서는 학습 epoch 수가 holographic 복원에서 Deep UNet 모델의 성능에 어떤 영향을 미치는지 분석했다. 동일한 네트워크 구조를 사용하여 각각 10, 20, 50 epoch 동안 학습시킨 세 가지 모델을 비교하였다. 학습에는 L1 손실 함수를 사용하였으며, 학습 손실과 검증 손실 모두 시간에 따라 결과를 추적했다.




Figure 6. Deep Model Epoch Comparison Results

손실 곡선 비교 결과, 학습 epoch 수를 늘릴수록 training loss는 꾸준히 감소하는 경향을 보였다. 하지만 10 epoch와 20 epoch 모델은 validation loss가 비교적 높고 불안정하게 나타났으며, 반면 50 epoch 모델은 validation loss가 더 낮고 부드럽게 수렴하는 양상을 보여 더 안정적인 성능을 나타냈다.

성능을 정량적으로 평가하기 위해, 각 모델을 10 mm 테스트 세트에 적용하고 복원된 진폭을 기반으로 평균 PSNR과 SSIM 값을 계산했다. 50 epoch 모델은 PSNR 22.19, SSIM 0.54로 가장 높은 성능을 기록했으며, 이는 더 나은 복원 품질을 의미한다. 이 결과는 학습을 더 오래 진행할수록 복원 성능이 향상된다는 것을 보여준다.

	PSNR_mean	SSIM_mean
epochs		
10	21.442138	0.459057
20	21.691220	0.491174
50	22.190730	0.548538

Figure 7. PSNR and SSIM Comparison of Deep Model by Epoch

학습 epoch 수의 영향을 더 명확히 확인하기 위해, 10 mm 테스트 세트에서 첫 번째 샘플을 사용해 각 모델의 복원 결과를 시각화 하였다.




Figure 8. Results of Reconstructed images of Epoch 10




Figure 9. Results of Reconstructed images of Epoch 20




Figure 10. Results of Reconstructed images of Epoch 50

위 그림에서 볼 수 있듯이, 50 epoch 모델은 특히 Amplitude에서 가장 선명한 복원 결과를 보여주었다. 반면, 10 epoch 모델은 Amplitude를 제대로 복원하지 못했으며, 20 epoch 모델은 어느 정도 개선된 결과를 보였지만, 여전히 50 epoch 결과에 비해 선명도가 부족했다. Deep model을 사용했기에, 세 경우 모두 나쁘지는 않았다. 대체적으로 Phase는 복원도가 모두 우수했고, Amplitude에서 차이를 확인할 수 있었다. 이러한 시각적 비교를 통해서도, epoch 수가 증가할수록 복원 품질이 향상된다는 것을 확인할 수 있었다. 이를 통해 정확도 높은 복원결과에는 충분한 epoch 수가 필요하다는 것을 알게 되었다.

1-3)

이 문제에서는 서로 다른 손실 함수들의 효과를 정량적으로 비교하기 위해, 이전 문제에서 사용했던 Deep 네트워크에 대해 학습된 모든 모델을 10 mm 거리에서 촬영된 테스트 세트에 대해 평가했고, PSNR과 SSIM 지표를 사용해 성능을 측정하였다. 실험에 사용된 세 가지 손실 함수(L1, L2, L1+SSIM) 중에서 L1+SSIM 손실 함수를 사용해 학습한 모델이 PSNR 22.27, SSIM 0.655로 가장 우수한 성능을 보였다. 이 결과는 L1 손실에 구조적 유사도 정보를 결합하면 이미지의 세부 정보와 구조를 더 잘 보존할 수 있으며, 이는 복소장 복원에서 중요한 요소임을 보여준다.

	Loss Function	PSNR_mean	SSIM_mean	n_samples
0	L1	21.629282	0.507073	50
1	L2	21.156037	0.476537	50
2	L1+SSIM	22.265120	0.655296	50

Figure 11. PSNR and SSIM Results for Different Loss Functions




Figure 12. Reconstruction Results Using L1 Loss Function




Figure 13. Reconstruction Results Using L2 Loss Function




Figure 14. Reconstruction Results Using L1+SSIM Loss Function

세 가지 손실 함수에 대한 시각적 복원 결과(Figures 12–14)를 비교해보면, L1+SSIM 손실 함수를 사용한 모델이 진폭과 위상 모두에서 가장 선명하고 정확한 복원 결과를 보였다. 특히 복잡한 경계와 미세 구조가 잘 보존되었으며, 위상 복원에서도 노이즈가 가장 적게 나타났다(Figure 14).

L1 손실 함수를 사용한 경우(Figure 12)는 진폭 복원에서 전반적으로 양호한 결과를 보였지만, 위상 복원에서는 다소 뭉개지는 영역과 세부 구조 손실이 관찰되었다. 이는 픽셀 간 차이만을 최소화하려는 L1의 특성상 구조적인 유사성을 충분히 반영하지 못했기 때문으로 보인다.

L2 손실을 적용한 결과(Figure 13)는 진폭과 위상 모두에서 가장 흐릿한 복원 결과를 보였다. 특히 위상 영상에서 뚜렷한 노이즈 패턴과 경계선 손상이 관찰되었으며, 이는 평균 제곱 오차 기반의 손실 함수가 이상치에 민감하고, 세부 정보 복원에 불리하다는 단점을 그대로 드러낸 결과다.

세 모델을 종합적으로 비교했을 때, L1+SSIM 손실 함수가 이미지의 국소 구조와 전반적인 품질을 동시에 잘 유지해주며, 복소장 복원에 가장 적합한 손실 함수임을 확인할 수 있다. 이는 앞서 제시된 PSNR 및 SSIM 정량 평가 결과와 일치한다.

1-4)

문제 1-4에서는 학습된 세 가지 모델(L1, L1+SSIM, L2)의 일반화 성능을 평가하기 위해, 훈련에 사용되지 않은 거리(5 mm, 15 mm, 20 mm)에서 촬영된 홀로그램을 입력으로 사용하였다. 평가 지표로는 PSNR과 SSIM을 사용하였다.




Figure 15. Generalization performance of three models across different distances

테스트 거리들이 학습 거리(10 mm)에서 멀어질수록 PSNR과 SSIM 모두 전반적으로 감소하는 경향을 보였으며, 이는 거리 변화에 따른 모델의 일반화 한계를 보여준다. 특히, SSIM의 경우 모든 모델에서 10 mm에서 가장 높은 값을 기록하고, 양쪽 거리(5 mm 및 20 mm)로 갈수록 급격히 감소하는 경향이 나타났다.

모델별로는 L1+SSIM 모델이 10 mm에서 가장 높은 SSIM(0.655)과 PSNR(22.26)을 기록했으나, 5 mm에서는 SSIM이 0.022로 급락하며 일반화에 취약한 모습을 보였다. 반면, L2 모델은 전체 거리 구간에서 PSNR과 SSIM의 변화 폭이 가장 작았으며, 특히 SSIM 기준으로 5 mm(0.099), 20 mm(0.191)에서도 상대적으로 안정적인 성능을 보였다. L1 모델은 PSNR이 전 구간에서 비교적 균일하게 유지되었지만, SSIM 값은 짧은 거리(5 mm)에서 0.10으로 낮게 나타났다.

결과적으로, SSIM 기준으로는 L2 모델이 가장 안정적인 일반화 성능을 보였고, L1+SSIM 모델은 훈련 거리에서는 매우 뛰어난 성능을 보였으나 테스트 거리 변화에는 민감한 경향을 나타냈다. 이러한 결과는 모델이 특정 거리 분포에 과적합될 경우, 예측 성능이 급격히 저하될 수 있음을 보여준다.

테스트 데이터의 첫번째 샘플을 사용하여 거리별 홀로그램 재구성 결과(5 mm, 15 mm, 20 mm)를 시각적으로 비교한 결과, 모델별로 명확한 차이점이 확인되었다. 특히, L1+SSIM 모델은 PSNR, 과 SSIM 상으로는 10 mm에서 가장 뛰어난 성능을 보였지만, 시각적으로는 짧은 거리(5 mm)에서 phase 이미지가 뭉개지는 듯한 모습이 관찰되었다. 이는 PSNR이나 SSIM 지표로 완전히 설명되지 않는 일반화 성능 저하를 뚜렷하게 보여준다.

반면, L2 모델은 전 거리에서 재구성 결과의 경계, 윤곽, 위상 구조가 비교적 일관적으로 유지되었다. 특히, 20 mm 재구성 이미지에서도 다른 모델에 비해 배경과 객체의 위상 구조가 선명하게 복원되었으며, 이는 L2 모델이 거리 변화에 상대적으로 robust 하다는 것을 보여준다.

L1 모델은 전체적으로 Amplitude 복원 품질은 안정적이었으나, phase 복원에서는 노이즈 성분과 흐림 현상이 나타났다. 15 mm나 20 mm의 결과에서는 phase 영역의 윤곽이 L2에 비해 뭉개져 있었고 색도 어두웠다. 이는 SSIM 값의 하락과 일치한다.

또한, Phase는 거리 변화에 훨씬 더 민감하며, 특히 L1 모델은 Phase 복원에 취약하다는 점을 발견했다. 이는 SSIM 손실이 Amplitude 이미지 품질에 특화되어 학습되었기 때문일 수 있으며, phase 복원까지 포함한 학습에는 추가적인 손실 함수나 구조가 필요함을 나타낸다.




Figure 16. Reconstructed Image at 5mm








Figure 17. Reconstructed Image at 15mm

Reconstruction at 20mm (1st sample)
GT Amplitude GT Phase





L1 Amplitude

L1 Phase



L1+SSIM Amplitude

L1+SSIM Phase



L2 Amplitude

L2 Phase





Figure 18. Reconstructed Image at 20mm

Problem 2

2-1)

이 문제에서는 실제 홀로그램 없이, 물리 기반 forward 모델로 생성한 합성 홀로그램을 이용해 self-supervised 학습을 진행했다. 실험에서는 기본 UNet 구조를 사용해 총 다섯 개의 모델을 학습했으며, 각각 고정된 거리(5 mm, 10 mm, 15 mm, 20 mm) 혹은 연속적인 거리 범위(5–20 mm)에서 생성된 데이터를 활용했다. 이후 동일한 테스트셋을 사용해 네 가지 거리(5 mm, 10 mm, 15 mm, 20 mm)에서 모델의 성능을 비교했다.

전체적으로 보면, 각 모델은 자신이 학습된 거리에서는 좋은 성능을 보였지만, 테스트 거리가 달라질수록 PSNR과 SSIM이 다소 떨어지는 경향을 보였다. 예를 들어, 5 mm 거리에서 학습된 모델(ss_5_5)은 같은 거리에서는 PSNR 16.37, SSIM 0.381로 비교적 준수한 결과를 냈지만, 20 mm에서는 PSNR 15.12, SSIM 0.228로 성능이 감소했다. 반대로, 20 mm에서 학습된 모델(ss_20_20)은 모든 거리에서 고르게 성능을 유지했다. 학습 거리가 멀어질수록 복원 대상이 단순해지는 특성이 이 결과에 영향을 준 것으로 판단된다.

전반적으로는 다양한 거리에서 생성된 데이터를 활용해 학습한 모델이 거리 변화에 더 잘 적응하는 모습을 보였으며, PSNR도 전반적으로 안정적인 수치를 유지했다. 다만 SSIM은 모든 모델에서 0.3 이하에 머무는 경우가 많았고, 이는 위상 복원 성능이 여전히 아쉬운 수준임을 보여준다. 네트워크의 표현력이나 손실 함수 구성 측면에서 개선의 여지가 있어 보인다.

```
=== Evaluating ss_5_5 ===
5mm → PSNR = 16.367, SSIM = 0.381
10mm → PSNR = 15.513, SSIM = 0.155
15mm → PSNR = 15.307, SSIM = 0.216
20mm → PSNR = 15.123, SSIM = 0.228

=== Evaluating ss_10_10 ===
5mm → PSNR = 19.112, SSIM = 0.226
10mm → PSNR = 19.234, SSIM = 0.304
15mm → PSNR = 19.086, SSIM = 0.250
20mm → PSNR = 19.055, SSIM = 0.250

=== Evaluating ss_15_15 ===
5mm → PSNR = 19.351, SSIM = 0.266
10mm → PSNR = 19.114, SSIM = 0.258
15mm → PSNR = 19.131, SSIM = 0.260
20mm → PSNR = 19.069, SSIM = 0.253

=== Evaluating ss_20_20 ===
5mm → PSNR = 20.001, SSIM = 0.298
10mm → PSNR = 19.833, SSIM = 0.246
15mm → PSNR = 19.901, SSIM = 0.269
20mm → PSNR = 19.904, SSIM = 0.273

=== Evaluating ss_5_20 ===
5mm → PSNR = 19.213, SSIM = 0.242
10mm → PSNR = 18.998, SSIM = 0.266
15mm → PSNR = 18.867, SSIM = 0.260
20mm → PSNR = 18.681, SSIM = 0.258
```

Figure 19. Quantitative evaluation of self-supervised models trained at different distances

각 거리(5 mm, 10 mm, 15 mm, 20 mm)에서 첫 번째 테스트 샘플에 대한 amplitude와 phase 복원 결과를 시각화하였다. Amplitude는 비교적 잘 복원된 반면, phase 결과는 전반적으로 품질이 낮았는데, 이는 홀로그램의 phase 정보 자체가 불안정하고 잡음에 민감한 특성을 갖고 있기 때문으로 보인다. 또한 기본 UNet 및 L1 손실함수를 사용했기 때문에 1-3번 문제에서 확인했듯이, phase를 제대로 복원하지 못한 것으로 판단된다.




Figure 20. Reconstruction Results at 5 mm and 10 mm




Figure 21. Reconstruction Results at 15 mm and 20 mm

추가적으로, 동일한 조건에서 기본 UNet과 Deep UNet 구조의 성능 차이를 간단히 비교해보았다. 두 모델 모두 self-supervised 방식으로 5 mm 거리에서 생성된 합성 홀로그램만을 사용하여 학습되었고, 이후 동일한 테스트 샘플(5 mm)에 대해 복원 결과를 시각화하였다. 좌측 열은 Deep UNet으로 학습한 결과이며, 우측 열은 기존 UNet으로 학습한 결과이다.

Amplitude 복원 측면에서는 두 모델 모두 유사한 패턴을 보였지만, phase 복원 결과는 확실한 차이를 보였다. Deep UNet의 phase 결과는 기본 UNet보다 상대적으로 디테일이 잘 보존된 형태를 나타내며, 전반적인 잡음도 적은 양상을 보였다. 이는 네트워크의 깊이가 phase 정보를 더 정교하게 학습하는 데 유리하게 작용했을 가능성을 보여준다.

다만, Deep UNet은 연산량이 훨씬 많아 전체 거리 범위에 대해 학습을 진행하는 데 시간이 오래 걸렸고, 제한된 시간으로 인해 현재는 일부 결과만 얻은 상태이다. 따라서 본 과제에서는 비교 결과를 참고 수준에서만 제시하게 되었다.




Figure 22. Comparison of Deep UNet(Left) and UNet(Right) Reconstructions at 5 mm (Self-Supervised, Trained on 5 mm)

2-2)

이 문제에서는 simulated hologram을 이용해 전파 거리를 예측하는 self-supervised depth regression 네트워크를 학습하였다. 학습 데이터는 5–20 mm 사이 임의의 거리에서 생성된 합성 홀로그램이며, 모델은 hologram 이미지를 입력으로 받아 거리를 직접 예측하도록 구성되었다. 이후 실제 테스트셋(5 mm, 10 mm, 15 mm, 20 mm)에 대해 평가를 진행한 결과, 10 mm에서의 MAE는 3.14 mm, 15 mm에서는 1.74 mm로 비교적 정확하게 거리를 예측했다. 20 mm에서는 6.66 mm, 5 mm에서는 7.93 mm의 오차를 보였지만, 중간 거리 구간에서는 전체적으로 안정적인 성능을 확인할 수 있었다. 별도의 거리 라벨 없이 intensity 정보만으로 전파 거리를 추정할 수 있었고, 이러한 방식은 수동으로 초점을 맞추지 않아도 선명한 복원을 가능하게 하는 auto-focusing 작업에도 활용해볼 수 있을 것으로 보인다.




Figure 22. Evaluation of predicted propagation distances using MAE and MSE

거리 추정의 성능 평가하기 위해, 학습된 depth regression 네트워크가 예측한 전파 거리를 이용해 amplitude와 phase 영상을 복원하였다. 이 네트워크는 5 mm부터 20 mm 사이에서 임의로 샘플링된 거리로 생성된 합성 홀로그램을 사용해 self-supervised 방식으로 학습했고, 평가 단계에서는 고정된 거리(5, 10, 15, 20 mm)의 실제 테스트 홀로그램을 입력으로 사용했다. 예측된 거리는 forward 모델에 전달되어 복원된 복소장을 생성하는데 사용되었다.

복원된 amplitude와 phase 이미지는 겉보기에는 참값과 유사하게 보였지만, 예측된 전파 거리는 대부분 13 mm 근처의 좁은 범위에 편향되어 있었다. 예를 들어, 실제 5 mm 입력에 대해서도 모델은 12.62 mm로 예측했다. 이런 결과는 모델이 거리 차이를 잘 구분하지 못했음을 보여준다.

이런 결과가 나타난 이유 중 하나는, 학습에 사용된 데이터는 5–20 mm 범위의 연속적인 거리에서 생성된 반면, 테스트 데이터는 정해진 특정 거리(5, 10, 15, 20 mm)에서 촬영되었기 때문이다. 모델이 학습 과정에서 자주 등장한 중간 거리 근처 값에 과도하게 적응하면서, 실제 거리와 무관하게 중간 값을 예측하는 경향을 보였을 가능성이 있다. 또한 intensity 정보만 입력으로 사용하는 구조와 네트워크가 비교적 얇은 구조로 되어 있어, 미세한 깊이 차이에 따른 phase 변화를 충분히 구분하지 못했을 수도 있다.




Figure 23. Reconstructed amplitude and phase at network-predicted distances

Extra credit problem

추가 문제로 홀로그래피 복원 문제에서의 OOD(Out-of-Distribution) 상황에 대해 탐구해보았다. OOD는 테스트 데이터가 학습 데이터의 분포와 크게 다를 때 발생하는 문제로, 대부분의 딥러닝 모델이 학습과 테스트 데이터가 동일한 분포에서 나온다고 가정하는 것과는 달리, 실제 환경에서는 이러한 가정이 성립하지 않는 경우가 많다. 예를 들어, 특정 전파 거리에서 촬영된 홀로그램만으로 학습한 모델은, 전혀 다른 거리에서 촬영된 데이터가 입력되었을 때 성능 저하를 겪을 수 있다.

이 문제를 실험적으로 확인하기 위해, 학습에는 5–20 mm 범위의 연속적인 거리에서 생성된 합성 홀로그램을 사용한 self-supervised 모델을 활용했다. 그 후, 학습 중 등장하지 않았던 거리인 2 mm와 25 mm에서 생성된 홀로그램을 OOD 테스트셋으로 사용하였다.

비교를 위해, 실제 10 mm 거리에서 촬영된 홀로그램만으로 supervised 방식으로 학습된 모델에 대해서도 동일한 테스트를 진행하였다. 이 모델은 학습 중 전파 거리의 변화에 노출되지 않은 상태였다.

복원 성능 평가는 예측된 amplitude와 ground-truth field 간의 PSNR 및 SSIM을 기준으로 이루어졌으며, 결과적으로 self-supervised 모델이 두 OOD 거리(2 mm, 25 mm) 모두에서 더 우수한 성능을 보여주었다. 특히 supervised 모델은 25 mm에서 급격한 성능 저하가 나타났으며, 이는 좁은 조건에 과도하게 적응(overfitting)된 결과로 해석될 수 있다. 반면, self-supervised 모델은 다양한 전파 거리에서의 학습을 통해 보다 넓은 상황에 대한 일반화 성능을 보여주었다.




Figure 24. PSNR and SSIM comparison at OOD distances (2 mm and 25 mm) between supervised and self-supervised models

위 결과는 홀로그램 재구성에서 OOD 문제가 얼마나 중요한지를 보여준다. 고정된 거리(10 mm)만으로 학습된 supervised 모델은 훈련에 포함되지 않은 거리에서 성능이 크게 떨어진다. 반면, 연속적인 거리 분포(5–20 mm)를 기반으로 self-supervised 방식으로 학습된 모델은 상대적으로 좋은 성능을 보였다.

이러한 결과는 실제 사용 환경처럼 전파 거리가 달라질 수 있는 상황에서는 다양한 조건으로 학습시키는 것이 매우 중요하다는 점을 강조한다.

이번 실험을 통해 홀로그램 재구성에서는 OOD 문제가 실제로 중요하다는 점과, 연속적인 거리 변화를 포함한 self-supervised 학습이 모델의 강건성을 높이는 효과적인 전략이라는 점을 확인할 수 있었다. 이 방식은 모델이 보지 못한 조건에 대해서도 더 잘 일반화하도록 만들기 때문에, 실제 현장에서의 활용 가능성을 높여준다.

모델의 OOD 조건에서의 반응을 평가하기 위해, 훈련 범위에 포함되지 않은 거리인 2 mm와 25 mm를 테스트 대상으로 선택했다. 이 거리에서 물리 기반 포워드 모델을 이용해 ground-truth 복소장을 기반으로 합성 홀로그램을 만들고, 이를 self-supervised 방식으로 학습된 모델(5–20 mm 학습)으로 재구성하였다. supervised 모델은 10 mm 단일 거리만으로 학습되었고 보지 못한 거리에서 성능이 불안정했기 때문에 이번 재구성에서는 사용하지 않았다.

2 mm에서는 재구성된 amplitude가 흐릿하고 디테일이 부족했으며, phase에서도 노이즈와 불안정한 패턴이 나타났다. 25 mm의 경우에는 amplitude는 어느 정도 구조적 특징을 유지했지만, phase에서는 간섭 패턴과 왜곡이 두드러졌다. 두 경우 모두, 훈련에 사용된 거리 범위 내에서의 결과에 비해 품질이 떨어지는 것을 확인할 수 있었다.




Figure 25. Reconstruction Results for Unseen Test Distances (2 mm and 25 mm)

Holography 복원 문제에서 OOD(Out-of-Distribution) 상황에 대응하기 위해서는, 학습 시 보지 못한 거리에서 입력이 들어오는 경우에도 성능이 유지되도록 딥러닝 모델을 설계하는 것이 중요하다. 이를 위한 한 가지 효과적인 방법은 self-supervised 방식처럼 연속적인 전파 거리 범위에서 학습하는 것이다. 이렇게 하면 특정 조건에 과적합(overfitting)되는 것을 방지하고, 보지 못한 테스트 상황에 대해서도 더 일반화된 복원 성능을 기대할 수 있다.

또한, 실제 데이터를 수집하지 않고도 OOD 상황을 시뮬레이션하기 위해, 물리 기반의 forward model을 활용해 특정 거리(예: 2 mm, 25 mm)에서의 합성 홀로그램을 생성할 수 있다. 이처럼 다양한 조건에서 모델을 평가하면, 실제 환경에서 발생할 수 있는 예외적인 상황에 대한 대응력을 높일 수 있다.

추가적으로, 모델이 softmax 출력을 제공하는 경우에는 입력에 작은 perturbation을 가하고 출력의 confidence 변화를 분석하는 ODIN과 같은 OOD 탐지 기법도 적용 가능하다. 이 외에도 정규화 기법이나 OOD 상황에 더 강건한 손실 함수(robust loss function)를 활용하는 것도 학습의 안정성과 일반화 성능을 높이는 데 도움이 된다.

결과적으로, 이러한 전략들은 딥러닝 기반 홀로그래피 복원을 실제 환경에 적용 가능한 수준으로 끌어올리는 데 중요한 역할을 한다. 이는 전파 거리가 정확히 알려지지 않거나 계속 변화할 수 있는 현실적인 조건에서도 안정적인 복원 성능을 기대할 수 있도록 한다.

가장 쉽게 접근할 수 있는 방법으로 학습범위를 2~25mm로 늘려 연속적인 거리 범위(랜덤 생성 거리 학습)로 학습을 진행해보았다. 그 결과 기존보다 Amplitude나 Phase의 경계들이 뚜렷해졌지만, 객관적으로 품질이 좋지는 못하다고 판단했다.




Figure 26. Reconstruction Results Using Expanded Training Range (2–25 mm) for OOD Distances

References

- [1] 양동헌, 황명권. “앙상블 기반 Out-of-Distribution 검출 방법.” *2020년도 추계학술대회*, 한국과학기술정보연구원, 과학기술연합대학원대학교.
- Yang, D., & Hwang, M.** (2020). *Out-of-Distribution Detection Based on Ensemble Method*. Fall Conference, Korea Institute of Science and Technology Information.
- [2] Liang, S., Li, Y., & Srikant, R. (2018). *Enhancing the Reliability of Out-of-Distribution Image Detection in Neural Networks*. In International Conference on Learning Representations (ICLR). arXiv:1706.02690v5.
- [3] Yang, J., Wang, H., Feng, L., Yan, X., Zheng, H., Zhang, W., & Liu, Z. (2021). *Semantically Coherent Out-of-Distribution Detection*. arXiv preprint arXiv:2108.11941v1.
- [4] Lakkapragada, A., Khanna, A., Raff, E., & Inkawhich, N. (2024). *Comprehensive OOD Detection Improvements*. arXiv preprint arXiv:2401.10176v1.